



Modelos de Regresión



Regresión lineal simple



¿Qué es un modelo de Regresión LINEAL?

Es un modelo o función que permite **predecir** el valor de **datos desconocidos** a partir de datos que SÍ son conocidos.

Ejemplo:

¿Recuerdas aquella vez en la que Homero Simpson decidió plantar "ToMacco?"



Homero empezó con un pequeño negocio que comenzó a crecer lentamente cuando se dio cuenta de que la gente se volvía adicta al ToMacco.



Homero vendía cada pieza de ToMacco en 1 Dólar, y registró las siguientes ganancias durante una semana:

Lunes: \$5

Martes: \$15

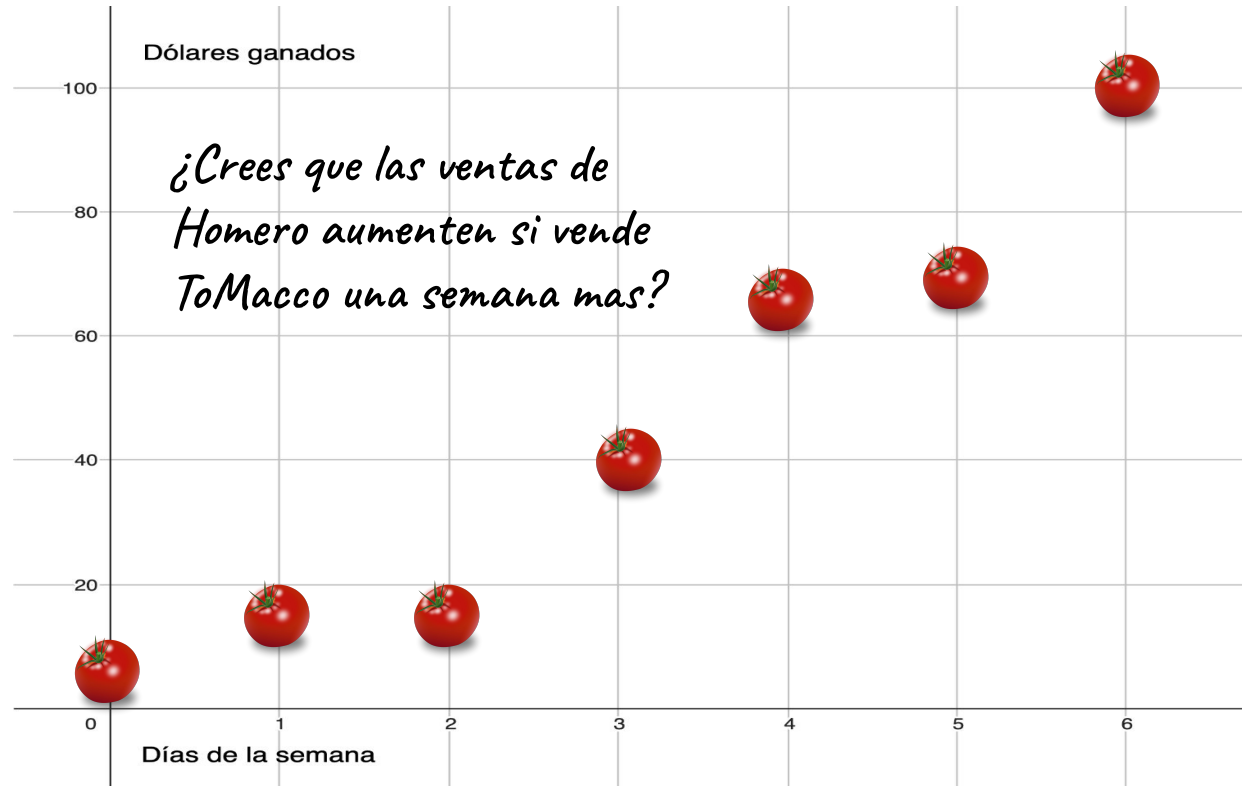
Miércoles: \$15

Jueves: \$40

Viernes: \$65

Sábado: \$70


Domingo: \$100



Podemos saberlo si creamos una **FUNCIÓN** que describa el **COMPORTAMIENTO** de los datos que tenemos:

Día	Venta de ToMacco
0	5
1	15
2	15
3	40
4	65
5	70
6	100

Para describir el comportamiento de datos usando una línea recta, podemos usar la ecuación de la recta:



Para lograr encontrar los parámetros de la función, utilizamos un método que se conoce como **AJUSTE** de **CURVAS** por **MÍNIMOS CUADRADOS**:

Día	Venta de ToMacco
0	5
1	15
2	15
3	40
4	65
5	70
6	100

$$\sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

El objetivo de este método consiste en minimizar la suma de los cuadrados de los errores

Podemos despejar: $\Sigma (y - \hat{y})^2 = \Sigma (mx + b - y_i)^2$

$$m = \frac{n\Sigma(x_i y_i) - \Sigma(x_i)(\Sigma y_i)}{n\Sigma(x_i^2) - (\Sigma x_i)^2}$$

$$b = \frac{(\Sigma y_i) - m(\Sigma x_i)}{n}$$

Para este ejemplo, podemos calcular los valores de m y b como:

$$m = \frac{n\sum(x_i y_i) - \sum(x_i)(\sum y_i)}{n\sum(x_i^2) - (\sum x_i)^2}$$

$$b = \frac{(\sum y_i) - m(\sum x_i)}{n}$$

Podemos generar una tabla con los valores de las sumatorias que vamos a necesitar para calcular m y b :

Día	Venta de ToMacco
0	5
1	15
2	15
3	40
4	65
5	70
6	100

n	x _i	y _i	x _i (y _i)	x _i *x _i	y _i *y _i
1	0	5	0	0	25
2	1	15	15	1	225
3	2	15	30	4	225
4	3	40	120	9	1600
5	4	65	260	16	4225
6	5	70	350	25	4900
7	6	100	600	36	10000
Total	21	310	1375	91	21200



Calculamos los valores de m y b :


$$m = \frac{n\Sigma(x_i * y_i) - \Sigma(x_i)\Sigma(y_i)}{n\Sigma(x_i^2) - (\Sigma x_i)^2}$$

n	xi	yi	xi(yi)	xi*xi	yi*yi
1	0	5	0	0	25
2	1	15	15	1	225
3	2	15	30	4	225
4	3	40	120	9	1600
5	4	65	260	16	4225
6	5	70	350	25	4900
7	6	100	600	36	10000
Total	21	310	1375	91	21200

$$\frac{7(1375) - (21)(310)}{7(91) - (21)^2} = \frac{9625 - 6510}{637 - 441} = \frac{3115}{196} = 15.892$$

$$b = \frac{\Sigma(y_i) - m\Sigma(x_i)}{n} = \frac{310 - (15.892)21}{7} = \frac{310 - 333.732}{7} = -3.39$$

Entonces ¿Cómo se ve la función que describe el comportamiento de las ventas de Homero?



Parece que las ventas de Homero van aumentando.
Woo Hoo!!!




¿Podríamos entonces *predecir* cuáles serían las ventas de Homero para los 10 días o para los 30 teniendo este modelo de regresión?

$$Y = mx + b = 15.892x - 3.39$$


$$f(x) = 15.892(10) - 3.39 = 155.53$$

$$Y = mx + b = 15.892x - 3.39$$

$$f(x) = 15.892(30) - 3.39 = 473.37$$



LISTO!!! tienes tu primer modelo de ML (Regresión lineal simple). Muchas felicidades!!!



Con esto puedes predecir las ganancias que homero tendría de aquí al infinito. Woo Hoo!!!



Es una lástima que le roben su ToMacco a Homero :/




Ahora es tu turno!!!

Día	Venta de ToMacco
0	4
1	6
2	22
3	38
4	72
5	80
6	110
7	112
8	124
10	135

*Con los nuevos datos...
Cuál será la ganancia para el
día 15?*

¿Y para el día 5.5?

Ejemplo de código:



```
# Importar las bibliotecas necesarias
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression

# Datos de ejemplo
X = np.array([1, 2, 3, 4, 5]).reshape(-1, 1) # Variable independiente
y = np.array([2, 4, 4.5, 4, 7])              # Variable dependiente

# Crear un modelo de regresión lineal
modelo = LinearRegression()

# Entrenar el modelo con los datos
modelo.fit(X, y)

# Realizar predicciones
y_pred = modelo.predict(X)

# Visualizar los resultados
plt.scatter(X, y, color='blue')                # Datos originales
plt.plot(X, y_pred, color='red')              # Línea de regresión
plt.xlabel('Variable independiente')
plt.ylabel('Variable dependiente')
plt.title('Regresión lineal')
plt.show()

# Imprimir los coeficientes de la regresión
print('Coeficiente:', modelo.coef_)
print('Intercepto:', modelo.intercept_)
```

Ejercicio de programación:

Programa DESDE CERO los siguientes ejemplos de regresión lineal:

n	xi	yi
1	1	4
2	3	6
3	4	22
4	7	38
5	10	72
6	12	80
7	15	110
8	22	112
9	31	124
10	40	135

n	xi	yi
1	1	4
2	2	6
3	4	9
4	6	25
5	10	25
6	13	47
7	16	42
8	19	64
9	25	83
10	30	80


Mostrar la gráfica con los puntos en cada caso, así como la recta generada.

Escribir los valores de m y b

Cuánto vale $f(50)$?

Regresión No lineal


Polinomial




Regresión No lineal (Polinomial)

Finalmente, en aquellos modelos que por la naturaleza de sus datos NO se puedan ajustar con una línea recta, se utilizan los modelos de regresión No lineal (o regresión polinomial).

La diferencia con los anteriores es que se define un valor polinomial (grado 2 o superior), y el algoritmo (código) se adapta a este exponente para intentar ajustarse a los datos o ejemplos:



Ejemplo de código:



```
# Importamos librerías
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import PolynomialFeatures
```

```
# Generar datos no lineales
np.random.seed(0)
X = 20 * np.random.rand(30, 1) - 10 # 30 Valores aleatorios entre -10 y 10
y = X**2 + 5 * np.random.randn(30, 1) # Función cuadrática con ruido
# 30 Valores de X elevada al cuadrado
# mas un valor aleatorio de 0 a 5
```

```
# Transformar las características para incluir términos polinomiales
```

```
grado_polynomial = 2
poly_features = PolynomialFeatures(degree=grado_polynomial)
X_poly = poly_features.fit_transform(X)
```

```
# Crear y entrenar un modelo de regresión lineal
```

```
modelo = LinearRegression()
modelo.fit(X_poly, y)
```

```
▼ LinearRegression
LinearRegression()
```